ΙΟΝΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ

ΜΑΘΗΜΑ:ΑΝΑΚΤΗΣΗ ΠΛΗΡΟΦΟΡΙΑΣ

ΦΟΙΤΗΤΕΣ:ΝΕΚΤΑΡΙΟΣ ΣΤΥΛΙΑΝΟΣ ΚΑΡΑΓΙΑΝΝΗΣ

AM:Inf2021078

ΚΑΘΗΓΗΤΕΣ: Κάτια - Λήδα Κερμανίδου , Στέργιος Παλαμάς

1η προαιρετική εργασία BONUS 2025-26

04/04/2026

ΠΙΝΑΚΑΣ ΠΕΡΙΕΓΧΟΜΕΝΩΝ

Περιεχόμενα

ΠΙΝΑΚΑΣ ΠΕΡΙΕΓΧΟΜΕΝΩΝ 2
ΕΙΣΑΓΩΓΗ 3
1. Εισαγωγή 3
2.ΑΣΚΗΣΕΙΣ 3
3. Τρόπος εργασίας 4
4. Παρεμβάσεις στον κώδικα της Άσκησης 1 4
4.1 Προσθήκη ανάλυσης ερωτήματος 4
4.2 Υλοποίηση AND queries 5
4.3 Υλοποίηση OR queries 5
4.4 Εμφάνιση αποτελεσμάτων 5
5. Παρεμβάσεις στον κώδικα της Άσκησης 2 5
5.2 Υποστήριξη πολλών όρων 6
5.3 Βελτιστοποίηση της εκτέλεσης 6
5.4 Εμφάνιση αποτελεσμάτων 6
6. Δοκιμές 6
7. Συμπεράσματα 7

ΕΙΣΑΓΩΓΗ

1. Εισαγωγή

Σκοπός της παρούσας εργασίας ήταν η μελέτη και η επέκταση δύο βασικών δομών ανάκτησης πληροφορίας που παρουσιάστηκαν στο μάθημα: του Binary Term–Document Incidence Matrix και του Inverted Index.
Η εργασία βασίστηκε στον αρχικό κώδικα του εργαστηρίου και στόχος ήταν να προστεθεί υποστήριξη Boolean ερωτημάτων, σύμφωνα με τις απαιτήσεις της εκφώνησης. Συγκεκριμένα, ζητήθηκε να υποστηρίζονται ερωτήματα με τελεστές AND και OR, να επιστρέφονται τα document IDs και τα ονόματα αρχείων των εγγράφων που ικανοποιούν το ερώτημα, και στην περίπτωση του Inverted Index να γίνει και βελτιστοποίηση της εκτέλεσης των ερωτημάτων.

2.ΑΣΚΗΣΕΙΣ

Άσκηση 1 Στην υλοποίηση με Python του Binary Term – Document Incidence Matrix (Πίνακας όρων – εγγραφών) που παρουσιάστηκε στο θεωρητικό και το εργαστηριακό μέρος του μαθήματος (βλέπε υλικό του e-class στη θεωρία και το εργαστήριο), να γίνουν οι ακόλουθες επεκτάσεις: Μετά την κατασκευή του Index, το πρόγραμμα να ζητάει από τον χρήστη να διατυπώσει ένα Boolean ερώτημα το οποίο θα απαντηθεί με χρήση του Index. Θα πρέπει να υποστηρίζονται ερωτήματα της μορφής :

term1 AND term2 AND term3 … AND termN

term1 OR term2 OR term3 … OR termN

Ως απάντηση να επιστρέφεται: Το query που υπέβαλε ο χρήστης Τα Document Ids των κειμένων που ικανοποιούν το query Τα ονόματα των αρχείων που αντιστοιχούν στα κείμενα που ικανοποιούν το query.

Άσκηση 2 Στην υλοποίηση με Python του Inverted Index (ανεστραμένου δείκτη) που παρουσιάστηκε στο θεωρητικό και το εργαστηριακό μέρος του μαθήματος (βλέπε υλικό του e-class στη θεωρία και το εργαστήριο), να γίνουν οι ακόλουθες επεκτάσεις: Εκτός από ερωτήματα με τελεστή AND, που είναι ήδη υλοποιημένα στον κώδικα, να υποστηρίζονται και ερωτήματα με τελεστή OR (τα ερωτήματα θα έχουν αποκλειστικά AND ή OR, Δε χρειάζεται να υποστηρίζονται ερωτήματα με

μεικτούς τελεστές) Να επεκτείνετε την υποστήριξη ερωτημάτων με AND και OR ώστε να υποστηρίζουν παραπάνω από 2 terms

(πχ term1 AND term2 AND term3 AND term4) .

Φροντίστε και για τη βελτιστοποίηση της εκτέλεσης των ερωτημάτων , σύμφωνα με αυτά που περιγράφονται στη θεωρία για τη βέλτιστη σειρά merging των posting lists των όρων (θα πρέπει δηλαδή να λάβετε υπόψη το μέγεθος του postings list κάθε όρου του query). Ως απάντηση να επιστρέφεται:

Το query που υπέβαλε ο χρήστης Τα Document Ids των κειμένων που ικανοποιούν το query Τα ονόματα των αρχείων που αντιστοιχούν στα κείμενα που ικανοποιούν το query.

3. Τρόπος εργασίας

Αρχικά μελετήθηκε ο κώδικας που δόθηκε στο εργαστήριο, ώστε να γίνει κατανοητός ο τρόπος με τον οποίο κατασκευάζεται ο πίνακας όρων–εγγράφων και ο ανεστραμμένος δείκτης. Στη συνέχεια χρησιμοποιήθηκαν τα αρχεία .txt της συλλογής κειμένων του εργαστηρίου και έγιναν δοκιμές για να επιβεβαιωθεί ότι ο αρχικός κώδικας λειτουργεί σωστά.Έπειτα, προστέθηκαν νέες συναρτήσεις για την επεξεργασία Boolean queries και την εμφάνιση των αποτελεσμάτων, χωρίς να αλλοιωθεί η βασική λογική του αρχικού προγράμματος.Τέλος, έγιναν δοκιμές με διαφορετικά ερωτήματα ώστε να επιβεβαιωθεί ότι οι τελεστές AND και OR λειτουργούν σωστά και ότι επιστρέφονται τα σωστά έγγραφα.

4. Παρεμβάσεις στον κώδικα της Άσκησης 1

Στην πρώτη άσκηση χρησιμοποιήθηκε η υλοποίηση του Binary Term–Document Incidence Matrix από το εργαστήριο.
Ο αρχικός κώδικας κατασκεύαζε το index, αλλά δεν υποστήριζε εκτέλεση Boolean ερωτημάτων από τον χρήστη. Για αυτόν τον λόγο έγιναν οι παρακάτω παρεμβάσεις:

4.1 Προσθήκη ανάλυσης ερωτήματος

Προστέθηκε συνάρτηση που διαβάζει το query και εντοπίζει αν περιέχει τον τελεστή AND ή τον τελεστή OR.
Επίσης, έγινε έλεγχος ώστε να μη γίνονται δεκτά μικτά ερωτήματα με AND και OR μαζί, αφού αυτό δεν ζητείται από την εκφώνηση.

4.2 Υλοποίηση AND queries

Για ερωτήματα της μορφής:

term1 AND term2 AND ... AND termN

χρησιμοποιήθηκε λογική τομή πάνω στα binary vectors των όρων. Ένα έγγραφο επιστρέφεται μόνο αν περιέχει όλους τους όρους του ερωτήματος.

4.3 Υλοποίηση OR queries

Για ερωτήματα της μορφής:

term1 OR term2 OR ... OR termN

χρησιμοποιήθηκε λογική ένωση πάνω στα binary vectors των όρων. Ένα έγγραφο επιστρέφεται αν περιέχει τουλάχιστον έναν από τους όρους του ερωτήματος.

4.4 Εμφάνιση αποτελεσμάτων

Προστέθηκε κώδικας ώστε, μετά την εκτέλεση του query, να εμφανίζονται:

- το query που υποβλήθηκε,
- τα Document IDs,
- τα ονόματα των αρχείων που ικανοποιούν το query.

5. Παρεμβάσεις στον κώδικα της Άσκησης 2

Στη δεύτερη άσκηση χρησιμοποιήθηκε η υλοποίηση του Inverted Index από το εργαστήριο.
Ο αρχικός κώδικας υποστήριζε μόνο ερωτήματα με τελεστή AND και συνήθως σε απλή μορφή. Ζητήθηκε να υποστηρίζονται και OR queries, περισσότερα από δύο terms, καθώς και βελτιστοποίηση στην εκτέλεση.

5.1 Προσθήκη υποστήριξης OR

Προστέθηκε νέα συνάρτηση για ερωτήματα με τελεστή OR, η οποία υπολογίζει την ένωση των postings lists των όρων. Με αυτόν τον τρόπο επιστρέφονται όλα τα έγγραφα που περιέχουν τουλάχιστον έναν από τους όρους.

5.2 Υποστήριξη πολλών όρων

Ο κώδικας επεκτάθηκε ώστε να μπορεί να εκτελεί ερωτήματα με περισσότερους από δύο όρους, όπως:

- term1 AND term2 AND term3
- term1 OR term2 OR term3

Έτσι, το σύστημα δεν περιορίζεται μόνο σε δυαδικά ερωτήματα αλλά μπορεί να χειριστεί γενικότερη μορφή Boolean queries.

5.3 Βελτιστοποίηση της εκτέλεσης

Για τα ερωτήματα με AND, εφαρμόστηκε βελτιστοποίηση σύμφωνα με τη θεωρία του μαθήματος.
Συγκεκριμένα, πριν από τη διαδικασία merging, τα postings lists ταξινομούνται με βάση το μέγεθός τους και η τομή ξεκινά από τις μικρότερες λίστες.
Η επιλογή αυτή μειώνει τον αριθμό των συγκρίσεων και κάνει την εκτέλεση πιο αποδοτική, ειδικά όταν το query περιέχει πολλούς όρους ή όταν υπάρχουν όροι με πολύ μεγάλα postings lists. Η εκφώνηση ζητά ρητά να ληφθεί υπόψη το μέγεθος των postings lists για τη βέλτιστη σειρά merging.

5.4 Εμφάνιση αποτελεσμάτων

Όπως και στην πρώτη άσκηση, προστέθηκε εμφάνιση:

- του query,
- των document IDs,
- των αντίστοιχων filenames.

6. Δοκιμές

Για τον έλεγχο της ορθής λειτουργίας του προγράμματος χρησιμοποιήθηκαν ενδεικτικά Boolean queries με τελεστές AND και OR.
Δοκιμάστηκαν τόσο ερωτήματα με δύο όρους όσο και ερωτήματα με περισσότερους όρους, ώστε να επιβεβαιωθεί ότι:

- τα αποτελέσματα είναι σωστά,
- οι τελεστές λειτουργούν όπως αναμένεται,

- η βελτιστοποίηση των postings lists δεν επηρεάζει την ορθότητα του αποτελέσματος αλλά μόνο την αποδοτικότητα.

7. Συμπεράσματα

Μέσα από την εργασία έγινε κατανοητή η διαφορά ανάμεσα στον πίνακα όρων–εγγράφων και στον ανεστραμμένο δείκτη, καθώς και ο τρόπος με τον οποίο μπορούν να χρησιμοποιηθούν για την απάντηση Boolean ερωτημάτων.
Επιπλέον, έγινε σαφές ότι ο Inverted Index είναι πιο αποδοτικός για την εκτέλεση αναζητήσεων, ιδιαίτερα όταν συνδυάζεται με βελτιστοποίηση στη σειρά merging των postings lists.
Η εργασία βοήθησε στην καλύτερη κατανόηση τόσο της θεωρίας όσο και της πρακτικής υλοποίησης βασικών τεχνικών της Ανάκτησης Πληροφορίας.