ΙΟΝΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ

ΦΟΙΤΗΤΕΣ:ΝΕΚΤΑΡΙΟΣ ΣΤΥΛΙΑΝΟΣ ΚΑΡΑΓΙΑΝΝΗΣ

ΚΑΘΗΓΗΤΕΣ:ΜΙΧΑΗΛ ΣΤΕΦΑΝΙΔΑΚΗΣ

ΜΑΘΗΜΑ:ΜΕΤΑΓΛΩΤΙΣΤΕΣ

AM:Inf2021078

ΕΡΓΑΣΙΑ 1

06/04/2026

ΠΙΝΑΚΑΣ ΠΕΡΙΕΓΧΟΜΈΝΩΝ

Περιεχόμενα

ΠΙΝΑΚΑΣ ΠΕΡΙΕΓΧΟΜΈΝΩΝ 2
ΕΙΣΑΓΩΓΗ 3
1.ΠΡΟΣΔΙΟΡΙΣΜΟΣ TOKENS 3
1.1ΠΙΝΑΚΑΣ TOKENS 3
2.ΕΥΡΕΣΗ ΚΑΝΟΝΙΚΩΝ ΕΚΦΡΑΣΕΩΝ 4
2.1 ΠΙΝΑΚΑΣ ΚΑΝΟΝΙΚΩΝ ΕΚΦΡΑΣΕΩΝ 4
3.ΣΕΙΡΑ ΔΗΛΩΣΗ PATTERNS 6
3.1 Η υλοποίηση του λεκτικού αναλυτή 6
4.ΚΑΤΑΣΚΕΥΗ ΚΩΔΙΚΑ ΚΑΙ ΔΟΚΙΜΑΣΤΙΚΟΥ ΚΕΙΜΕΝΟΥ ΕΙΣΟΔΟΥ 7
4.1 ΔΗΛΩΣΗ PATTERNS 7
5.ΑΝΑΦΟΡΕΣ 8
5.1ΔΟΚΙΜΕΣ 8
6.ΠΗΓΕΣ 9
6.1 ΠΗΓΕΣ 9
7.ΧΡΗΣΗ ΤΕΧΝΗΤΗΣ ΝΟΥΜΟΣΥΝΗΣ 10
7.1 ΕΡΓΑΛΕΙΑ TN 10

ΕΙΣΑΓΩΓΗ

Στην παρούσα εργασία μελετάται η διαδικασία της λεκτικής ανάλυσης (lexical analysis) και υλοποιείται ένας λεκτικός αναλυτής για το μορφότυπο JSON5. Η λεκτική ανάλυση αποτελεί το πρώτο στάδιο ενός μεταγλωττιστή και έχει ως στόχο τη μετατροπή του πηγαίου κώδικα σε μια ακολουθία από tokens, δηλαδή βασικές μονάδες πληροφορίας όπως λέξεις-κλειδιά, αναγνωριστικά, αριθμούς και σύμβολα.

Το JSON5 αποτελεί επέκταση του JSON, παρέχοντας μεγαλύτερη ευελιξία στη γραφή δεδομένων, όπως υποστήριξη σχολίων, μη quoted ονομάτων ιδιοτήτων και πιο εκφραστικών αριθμητικών μορφών. Η ύπαρξη αυτών των χαρακτηριστικών καθιστά τη λεκτική ανάλυση πιο σύνθετη σε σχέση με το απλό JSON.

Στο πλαίσιο της εργασίας, σχεδιάστηκε και υλοποιήθηκε ένας λεκτικός αναλυτής χρησιμοποιώντας κανονικές εκφράσεις και την κλάση Tokenizer της βιβλιοθήκης του εργαστηρίου. Ο αναλυτής αναγνωρίζει τα βασικά στοιχεία του JSON5, αγνοεί σχόλια και λευκούς χαρακτήρες, και εντοπίζει σφάλματα σε μη έγκυρη είσοδο.

Η εργασία οργανώνεται ως εξής: αρχικά προσδιορίζονται τα tokens του JSON5, στη συνέχεια παρουσιάζονται οι κανονικές εκφράσεις που χρησιμοποιήθηκαν, ακολουθεί η ανάλυση της σειράς προτεραιότητας των patterns, και τέλος παρουσιάζεται η υλοποίηση και τα αποτελέσματα δοκιμών του λεκτικού αναλυτή.

1.ΠΡΟΣΔΙΟΡΙΣΜΟΣ TOKENS

1.1ΠΙΝΑΚΑΣ TOKENS

LBRACE	Το σύμβολο {, που δηλώνει την αρχή αντικειμένου JSON5.
RBRACE	Το σύμβολο }, που δηλώνει το τέλος αντικειμένου JSON5.
LBRACKET	Το σύμβολο [, που δηλώνει την αρχή πίνακα JSON5.
RBRACKET	Το σύμβολο], που δηλώνει το τέλος πίνακα JSON5.
COLON	Το σύμβολο :, που χωρίζει κλειδί και τιμή σε ένα αντικείμενο.
COMMA	Το σύμβολο ,, που χωρίζει στοιχεία πίνακα ή ζεύγη κλειδιού-τιμής.
IDENTIFIER	Μη quoted όνομα ιδιότητας, σύμφωνα με το JSON5. Στην εργασία θεωρήθηκαν μόνο χαρακτήρες ASCII.

STRING	Συμβολοσειρά μέσα σε μονά ή διπλά εισαγωγικά.
NUMBER	Αριθμητική σταθερά σε δεκαδική μορφή, με δυνατότητα προσήμου, δεκαδικού μέρους και εκθέτη.
HEXNUMBER	Αριθμητική σταθερά σε δεκαεξαδική μορφή, π.χ. 0xFF.
TRUE	Η λεκτική σταθερά true.
FALSE	Η λεκτική σταθερά false.
NULL	Η λεκτική σταθερά null.
WHITESPACE	Κενά, tabs και αλλαγές γραμμής. Αναγνωρίζονται αλλά απορρίπτονται.
LINE_COMMENT	Σχόλιο μιας γραμμής που αρχίζει με //. Αναγνωρίζεται αλλά απορρίπτεται.
BLOCK_COMMENT	Σχόλιο πολλών γραμμών ανάμεσα σε /* και */. Αναγνωρίζεται αλλά απορρίπτεται.
ERROR	Οποιοσδήποτε χαρακτήρας δεν ταιριάζει με κανένα άλλο pattern και οδηγεί σε σφάλμα λεκτικής ανάλυσης.

2.ΕΥΡΕΣΗ ΚΑΝΟΝΙΚΩΝ ΕΚΦΡΑΣΕΩΝ

2.1 ΠΙΝΑΚΑΣ ΚΑΝΟΝΙΚΩΝ ΕΚΦΡΑΣΕΩΝ

Token / Ομάδα tokens	**Κανονική έκφραση**	**Σύντομη εξήγηση**
WHITESPACE	[\t\n\r]+	Αναγνωρίζει ένα ή περισσότερα κενά, tab, newline ή carriage return. Χρησιμοποιείται για την παράλειψη λευκών χαρακτήρων.
LINE_COMMENT	//[^\n\r]*	Αναγνωρίζει σχόλιο μίας γραμμής που ξεκινά με // και συνεχίζει μέχρι το τέλος της γραμμής.
BLOCK_COMMENT	/*[\s\S]*?*/	Αναγνωρίζει σχόλιο πολλών γραμμών ανάμεσα σε /* και */.

		Χρησιμοποιείται το [\s\S] ώστε να επιτρέπονται και αλλαγές γραμμής.
LBRACE	\{	Αναγνωρίζει το σύμβολο {.
RBRACE	\}	Αναγνωρίζει το σύμβολο }.
LBRACKET	\[	Αναγνωρίζει το σύμβολο [.
RBRACKET	\]	Αναγνωρίζει το σύμβολο].
COLON	:	Αναγνωρίζει το σύμβολο :.
COMMA	,	Αναγνωρίζει το σύμβολο ,.
IDENTIFIER	[$A-Za-z_][$A-Za-z0-9_]*	Αναγνωρίζει μη quoted ονόματα ιδιοτήτων JSON5. Το πρώτο σύμβολο μπορεί να είναι $, γράμμα ή _, και τα επόμενα μπορεί να είναι γράμματα, ψηφία, $ ή _. Έγινε ο περιορισμός σε ASCII όπως ζητά η εκφώνηση.
TRUE, FALSE, NULL	μέσω IDENTIFIER με keywords	Οι λέξεις true, false, null αναγνωρίζονται πρώτα από το pattern του identifier και έπειτα αντιστοιχίζονται σε ειδικά tokens με τον μηχανισμό keywords της Tokenizer.
HEXNUMBER	[+-]?0[xX][0-9a-fA-F]+	Αναγνωρίζει προαιρετικό πρόσημο, έπειτα 0x ή 0X, και μετά ένα ή περισσότερα δεκαεξαδικά ψηφία.
NUMBER	`[+-]?(?:\d+.\d+	\d+.
STRING με διπλά	`"(?:\.	[^"\])*"`

εισαγωγικά		
STRING με μονά εισαγωγικά	`'(?:\.	[^'\])*'`
ERROR	.	Αναγνωρίζει οποιονδήποτε μεμονωμένο χαρακτήρα δεν αναγνωρίστηκε νωρίτερα και προκαλεί σφάλμα λεκτικής ανάλυσης.

Οι κανονικές εκφράσεις επιλέχθηκαν έτσι ώστε να καλύπτουν τα βασικά λεκτικά στοιχεία του JSON5 που απαιτούνται για την εργασία. Για τα keywords true, false και null δεν χρησιμοποιήθηκαν ξεχωριστές κανονικές εκφράσεις, αλλά αξιοποιήθηκε η δυνατότητα keywords της κλάσης Tokenizer, ώστε οι συγκεκριμένες λεκτικές μορφές να επιστρέφονται ως ξεχωριστά tokens αντί για IDENTIFIER.

Η υλοποίηση καλύπτει σε ικανοποιητικό βαθμό τα βασικά tokens του JSON5, αλλά δεν ακολουθεί απόλυτα όλη τη λεπτομέρεια της προδιαγραφής. Συγκεκριμένα:

- Τα IdentifierName έχουν περιοριστεί σε χαρακτήρες ASCII, όπως ζητείται ρητά από την εκφώνηση, ενώ η πλήρης προδιαγραφή JSON5 επιτρέπει ευρύτερο σύνολο Unicode χαρακτήρων.
- Τα strings υλοποιήθηκαν με πρακτικές κανονικές εκφράσεις που καλύπτουν escaped characters και μονά/διπλά εισαγωγικά, αλλά δεν ελέγχουν εξαντλητικά κάθε ειδική περίπτωση escape της πλήρους προδιαγραφής.
- Δεν συμπεριλήφθηκαν ειδικές αριθμητικές τιμές όπως Infinity και NaN, παρότι αναφέρονται στη JSON5 προδιαγραφή.
- Η λεκτική ανάλυση δεν ελέγχει συντακτική ορθότητα· αναγνωρίζει μόνο tokens, όπως ζητά η εργασία.

3.ΣΕΙΡΑ ΔΗΛΩΣΗ PATTERNS

3.1 Η υλοποίηση του λεκτικού αναλυτή

Η υλοποίηση του λεκτικού αναλυτή καλύπτει τα βασικά στοιχεία της προδιαγραφής JSON5, αλλά υπάρχουν ορισμένοι περιορισμοί:

- Τα IdentifierName περιορίζονται σε χαρακτήρες ASCII, όπως ζητείται από την εκφώνηση, ενώ η πλήρης προδιαγραφή JSON5 υποστηρίζει Unicode.
- Τα strings υποστηρίζουν escape sequences σε βασικό επίπεδο, αλλά δεν καλύπτονται όλες οι ειδικές περιπτώσεις της προδιαγραφής JSON5.
- Δεν υποστηρίζονται οι ειδικές αριθμητικές τιμές Infinity και NaN.
- Δεν γίνεται έλεγχος συντακτικής ορθότητας, καθώς ο λεκτικός αναλυτής περιορίζεται στην αναγνώριση tokens.

4.ΚΑΤΑΣΚΕΥΗ ΚΩΔΙΚΑ ΚΑΙ ΔΟΚΙΜΑΣΤΙΚΟΥ ΚΕΙΜΕΝΟΥ ΕΙΣΟΔΟΥ

4.1 ΔΗΛΩΣΗ PATTERNS

- [\t\n\r]+ → IGNORE
  ➤ Πρέπει να δηλωθεί πρώτο για να αγνοούνται τα κενά πριν αναγνωριστούν άλλα tokens.
- //[^\n\r]* → IGNORE
  ➤ Πριν από / ή άλλα patterns για να αναγνωρίζονται σωστά τα line comments.
- /*[\s\S]*?*/ → IGNORE
  ➤ Πριν από άλλα patterns που περιέχουν /.
- \{ → LBRACE
- \} → RBRACE
- \[→ LBRACKET
- \] → RBRACKET
- : → COLON
- , → COMMA
  1. ➤ Τα σύμβολα δηλώνονται νωρίς γιατί είναι απλά και δεν συγκρούονται με άλλα patterns.
- [$A-Za-z_][$A-Za-z0-9_]* → IDENTIFIER (+ keywords)
  ➤ Πρέπει να δηλωθεί πριν από ERROR ώστε να αναγνωρίζονται identifiers και keywords.
- [+-]?0[xX][0-9a-fA-F]+ → HEXNUMBER
  ➤ Πρέπει να δηλωθεί πριν από NUMBER για να μην αναγνωρίζεται το 0 μόνο.

- [+-]?(?:\d+\.\d+|\d+\.|\.\d+|\d+)(?:[eE][+-]?\d+)? → NUMBER
  ➤ Αναγνωρίζει όλες τις δεκαδικές μορφές αριθμών.
- "(?:\\.|[^"\\])*" → STRING
- '(?:\\.|[^'\\])*' → STRING
  ➤ Πρέπει να δηλωθούν πριν από ERROR για να αναγνωρίζονται σωστά τα strings.
- . → ERROR
  ➤ Τελευταίο pattern, για να πιάσει οποιονδήποτε μη αναγνωρισμένο χαρακτήρα.

5.ΑΝΑΦΟΡΕΣ

5.1ΔΟΚΙΜΕΣ

Βάλε αυτό:

```
{
  // line comment
  unquotedKey: 'hello',
  "quotedKey": "world",
  age: 25,
  price: -12.5,
  hexValue: 0xFF,
  positive: +10,
  fraction: .75,
  exponent: 1.2e3,
  isActive: true,
  isDeleted: false,
  emptyValue: null,
  list: [1, 2, 3,],
  nested: {
    another_key: "text"
  }
  /* block comment */
}
```

Το παραπάνω κείμενο περιλαμβάνει όλα τα βασικά είδη tokens:

- { και } → LBRACE, RBRACE
- [και] → LBRACKET, RBRACKET

- : → COLON
- , → COMMA
- unquotedKey, age, nested → IDENTIFIER
- 'hello', "world", "text" → STRING
- 25, -12.5, +10, .75, 1.2e3 → NUMBER
- 0xFF → HEXNUMBER
- true, false, null → TRUE, FALSE, NULL
- // ... → LINE_COMMENT (αγνοείται)
- /* ... */ → BLOCK_COMMENT (αγνοείται)
- whitespace → αγνοείται
  Το δοκιμαστικό input επιβεβαιώνει ότι ο λεκτικός αναλυτής μπορεί να αναγνωρίσει όλα τα είδη tokens που έχουν υλοποιηθεί.

6.ΠΗΓΕΣ

6.1 ΠΗΓΕΣ

- JSON5 Specification – Η επίσημη προδιαγραφή του JSON5, από την οποία προέκυψαν τα tokens και οι κανόνες λεκτικής ανάλυσης.
- Python re module documentation – Τεκμηρίωση για τη σύνταξη και χρήση κανονικών εκφράσεων στην Python.
- Writing a Tokenizer (Python docs example) – Παράδειγμα δημιουργίας tokenizer με κανονικές εκφράσεις.
- Οι σημειώσεις και τα παραδείγματα του εργαστηρίου χρησιμοποιήθηκαν ως κύρια βάση για τη χρήση της κλάσης Tokenizer.
- Υλη του μαθήματος
- https://www.youtube.com/watch?v=5pf0_bpNbkw βίντεο εκμάθησης στο youtube
- https://www.youtube.com/watch?v=iiADhChRriM βίντεο εκμάθησης στο youtube

7.ΧΡΗΣΗ ΤΕΧΝΗΤΗΣ ΝΟΥΜΟΣΥΝΗΣ

7.1 ΕΡΓΑΛΕΙΑ ΤΝ

Κατά την εκπόνηση της εργασίας χρησιμοποιήθηκαν εργαλεία τεχνητής νοημοσύνης για υποστηρικτικούς σκοπούς.

- Χρησιμοποιήθηκαν για την κατανόηση της προδιαγραφής JSON5 και τη διάσπαση του προβλήματος σε επιμέρους βήματα.
- Βοήθησαν στη διαμόρφωση των κανονικών εκφράσεων για τα tokens.
- Χρησιμοποιήθηκαν για την καθοδήγηση στην υλοποίηση του λεκτικού αναλυτή με χρήση της κλάσης Tokenizer.
- Αξιοποιήθηκε ως εργαλείο υποστήριξης κατά την επαλήθευση του κώδικα.